

RAG et Agents IA

Charles de Dampierre



Louis-Marie Lorin



Malte Meng



Nathan Tessot



Tassilo Westphalen



Le RAG

Qu'est-ce que le **RAG** ?


Problème.

- Données obsolètes
- Hallucinations
- absence de traçabilité

Solution (RAG). Retrieval-Augmented Generation


- Mémoire **dynamique**
- Connaissances mises à jour
- Fournit le contexte exact nécessaire pour répondre à une requête

Les 3 phases du RAG.




Phase 1 : Indexation

1. Ingestion des documents




Phase 1 : Indexation

2.Chunking




Phase 1 : Indexation

3. Embeddings (vectorisation)




[0.257, 3.936, ..., 5.702]



Phase 1 : Indexation




3. Embeddings (vectorisation)

Comment entraîner un embedding ?




Phase 1: Indexation

3. Embeddings (vectorisation)





Phase 1: Indexation

3. Embeddings (vectorisation)




Phase 1 : Indexation

4. Base de données vectorielle




Phase 2 : Retrieval

1. Vectorisation de la requête




[7.482, 0.364, ..., 5.916]



Phase 2 : Retrieval

1. Vectorisation de la requête

Optimisation (*HyDE*) :



Variante 1 → [6.402, 0.963, ..., 6.175]

Variante 2 → [7.630, 0.947, ..., 5.486]

Réponse rapide

La gestion d'une surchauffe (ou excursion thermique) dans un réacteur nucléaire ou chimique est une procédure critique qui repose sur une hiérarchie d'actions immédiates. L'objectif est de stabiliser la température avant d'atteindre le point de non-retour ou l'endommagement de l'enceinte.



Voici les étapes standards de sécurité :

→ [6.482, 1.539, ..., 6.947]

Phase 2 : Retrieval

2. Recherche sémantique

Cosine Similarity




Phase 2 : Retrieval

2. Recherche sémantique

Optimisation : *Hybrid Search*

Recherche sémantique




+

Recherche par mot-clés



Phase 2 : Retrieval


3. Extraction des Top-K Chunks



Phase 2 : Retrieval


3. Extraction des Top-K Chunks

Optimisation : Re-Ranking



Phase 3 : Génération

1. Le ✨ Super-prompt ✨



Phase 3 : Génération

1. Le ✨ Super-prompt ✨

Tu es un expert en ingénierie nucléaire. Utilise uniquement le contexte fourni pour répondre. Si l'information est absente, indique-le clairement.

Contexte :

- *Top-1 Chunk*
- *Top-2 Chunk*
- ...

Réponds à la question : “Que faut-il faire en cas de surchauffe du réacteur ?”


Instruction système

Contexte (Top-K Chunks)

Requête initiale


Phase 3 : Génération

2. Traitement par le LLM




Phase 3 : Génération

2. Traitement par le LLM



Phase 3 : Génération

3. Réponse finale augmentée



Phase 3 : Génération

3. Réponse finale augmentée

Mesurer la qualité de la réponse

- Précision
- Fidélité
- Pertinence

Limites du **RAG**.

À ne pas utiliser lorsque :

- La **latence** est extrêmement critique
- La tâche nécessite une synthèse **macroscopique**



Agents IA



Contexte et Définition

Propriétés Fondamentales

- Autonomie
- Réactivité
- Proactivité
- Capacité sociale

RAISONNE	DÉCIDE	PERÇOIT	COLLABORE
Planifie et mémorise	Autonome, s'adapte	Texte, voix, image, code	Coordonne d'autres agents



Contexte et Définition

Workflow

- PROCESSUS POUR RATIONALISER LES TÂCHES ET LES ACTIVITÉS

Framework

- BIBLIOTHÈQUE LOGICIELLE QUI ABSTRAIT LES COUCHES COMPLEXES D'UN AGENT

Agentic AI

- NIVEAU D'AUTONOMIE
- 1 OU PLUSIEURS AGENTS
- PLANIFIE, DÉCIDE, S'ADAPTE

Système multi-agents (MAS)

- ARCHITECTURE
- PLUSIEURS AGENTS
- COOPÉRATION DES AGENTS







Figure 3. A Venn diagram illustrating the conceptual foundations of agentic AI.

Milestones

ReAct Agent architecture



2022

ReAct

Le premier agent LLM qui alterne raisonnement et action en boucle. Pose les bases de tous les agents modernes




Milestones



AutoGPT

Premier agent grand public, il se donne lui-même des sous-tâches pour atteindre un objectif. Viral sur internet, montre le potentiel mais aussi les limites (boucles infinies, hallucinations).






Milestones

2023

Voyager

Agent qui joue à Minecraft de façon autonome. Premier agent à construire une bibliothèque de compétences qui s'enrichit au fil du temps







Milestones

2023

ChatGPT Plugins

GPTs OpenAI intègre les outils directement dans ChatGPT. Démocratise le concept d'agent pour le grand public






Milestones

2024

Gemini Deep Research

Agent de recherche autonome — lit des dizaines de sources, synthétise, produit un rapport complet. Exemple parfait de planification multi-étapes.







Milestones

2025

Claude Code

Agent de développement qui travaille directement dans ton terminal, lit ta codebase entière, exécute des commandes. Conçu pour une autonomie maximale sur des tâches longues.



Les caractéristiques d'un **Agent IA**

RAISONNEMENT

PLANIFICATION

EXÉCUTION

COLLABORATION

OBSERVATION

AUTO-AMÉLIORATION

POUR

Efficacité et Productivité



Amélioration de la prise de décision



Functionalités améliorées



Simulations



Flight Simulator

CONTRE

Empathie & émotions

CHATBOT CLIENT AVEC MANQUE D'EMPATHIE

Enjeux éthiques

DISCRIMINATION

Environnements imprévisibles

RÉACTION FACE À DES IMPRÉVUS

Ressources

CONSOMATION D'ENERGIE

Productivité

[HTTPS://WWW.ANTHROPIC.COM/RESEARCH/ESTIMATING-PRODUCTIVITY-GAINS](https://www.anthropic.com/research/estimating-productivity-gains)

80% DE GAIN DE PRODUCTIVITÉ

MAIS UNE PERTE DE TEMPS À LA VÉRIFICATION DE CE QUE FAIT L'AGENT

Estimating Claude's productivity impacts

We use Claude to estimate how long it would take people to do real-world tasks with and without AI assistance

 Claude, given the following transcript:


 User: Given this source material, can you write a memo? [...]

 Assistant: Here it is [...]


Think for 2-5 sentences then output just a number

 1.5

Tasks associated with higher-wage occupations (e.g. lawyers, programmers, or managers) tend to take more time



Based on current capabilities, the estimated time savings suggests an additional 1.8% annual labor productivity growth, assuming full adoption in 10 years



Cas d'utilisation

**Tâche trop complexe pour
un seul modèle**

Outils externes requis (APIs, BDD)

**Environnement dynamique et
changeant**

Parallélisation possible

Mémoire long terme nécessaire

**Planification multi-étapes
indispensable**

Cas de non utilisation

Tâche simple et répétitive

Explicabilité obligatoire

Latence critique

Risques de sécurité (injection de prompts)

Zéro tolérance aux erreurs (santé, finance)

Coût computationnel inacceptable

Les systèmes pré-existants

Chronologie	Type de système	Technologie	Limite
1	Agents IA classiques (réactif, modèle, objectif, apprenant)	Règles, arbres de décision, architecture BDI	Rigides, pas d'improvisation

Les systèmes pré-existants

Chronologie	Type de système	Technologie	Limite
2	MAS (Multi-Agent Systems)	Coordination d'agents	Basé sur des règles prédéfinies pour agents classiques

Les systèmes pré-existants

Chronologie	Type de système	Technologie	Limite
3	LLM-based Agents (post-2022)	LLM + outils externes	Agent unique, tâches bien définies

Les systèmes pré-existants

Chronologie	Type de système	Technologie	Limite
4	Agentic AI (post-2023)	Haute autonomie, décomposition des tâches	Planification imparfaite et fiabilité du raisonnement

Les catégories d'agents

Catégorie d'agent	Description
Simple Reflex Agents	Réagit uniquement selon des règles condition-action prédéfinies, sans mémoire ni raisonnement.

Les catégories d'agents

Catégorie d'agent	Description
Model-Based Reflex Agents	Maintient un modèle interne du monde pour prendre de meilleures décisions dans des environnements partiellement observables.

Les catégories d'agents

Catégorie d'agent	Description
Goal-Based Agents	Choisit ses actions en fonction d'objectifs explicites, en raisonnant sur les moyens d'y parvenir.

Les catégories d'agents

Catégorie d'agent	Description
Utility-Based Agents	Évalue et compare la désirabilité des différents résultats possibles via une fonction d'utilité pour optimiser ses décisions.

Les catégories d'agents

Catégorie d'agent	Description
Learning Agents	Améliore ses performances au fil du temps en apprenant de ses expériences passées.

Les catégories d'agents

Catégorie d'agent	Description
Hierarchical Agents	Décompose des tâches complexes en sous-tâches confiées à des agents de niveau inférieur.

Les catégories d'agents

Catégorie d'agent	Description
LLM-Based Agents / Agentic AI	Exploite les capacités de raisonnement des grands modèles de langage, enrichies d'outils, de mémoire et de planification autonome.

Fonctionnement d'un **Agent IA Simple**





Figure 2: Overview of LLM-based agents

Orchestrator



Fonctionnement d'un **Systeme à Multi-Agents**




Figure 3: The Relationship between LLM-based agents

Fonctionnement précis d'un système à agent unique



Figure 4: Typology of the Planning capability.





Figure 5: Typology of the Memory.







Figure 6: Typology of the Rethinking capability.

Framework ReAct






Figure 7: Typology of the Environment.





Figure 8: Typology of the Actions.

Environnement d'exécution conteneurisation



Use Case

